


در این گزارش سعی بر این شده است که شاخص آلودگی پنج منطقه مورد بررسی قرار بگیرد و آینده ی آن مورد پیش بینی قرار گیرد.

در ابتدا داده هم مورد بررسی قرار می گیرد، میزان آلودگی برای هر منطقه به صورت ساعت به ساعت داده شده است، برای اینکه در این حالت تعداد داده ها بسیار زیاد می باشد و سیستمی که با آن این بررسی انجام شده است ضعیف بوده است، علاوه بر داده های ساعت به ساعت داده ها به صورت روزانه هم تعریف شده اند بدین نحو که در هر روز شاخص آلودگی برابر میانگین ساعات مختلف روز قرار گرفته شده است تا در صورت لزوم و ناتوانایی سیستم داده های روزانه مورد استفاده قرار گیرد .


سری زمانی داده های ساعت به ساعت و روز به روز برای مناطق مختلف به صورت زیر می شود.

منطقه ی مرکزی :

daily Pollutant Standards Index (PSI) in central Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in central Singapore from 2016 to 2020.




ناحیه غرب

daily Pollutant Standards Index (PSI) in west Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in west Singapore from 2016 to 2020.




ناحية شرق

daily Pollutant Standards Index (PSI) in east Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in east Singapore from 2016 to 2020.




ناحية جنوب

daily Pollutant Standards Index (PSI) in south Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in south Singapore from 2016 to 2020.




ناحيه شمال

daily Pollutant Standards Index (PSI) in north Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in north Singapore from 2016 to 2020.




كل کشور

daily Pollutant Standards Index (PSI) in national Singapore from 2016 to 2020.




hourly Pollutant Standards Index (PSI) in national Singapore from 2016 to 2020.




حال برای اینکه بتوانیم درک بهتری از داده ها داشته باشیم **box plot** سال های مختلف ، ماه های مختلف سال ، روز های مختلف سال و روز های مختلف هفته را برای نواحی مختلف رسم می کنیم
برای ناحیه مرکز :


Year-wise Box Plot
central




day_of_week Box Plot
central



Month-wise Box Plot
central




day_of Month Box Plot
central




برای غرب


Year-wise Box Plot
west




day_of_week Box Plot
west



Month-wise Box Plot
west




day_of Month Box Plot
west




برای شرق


Year-wise Box Plot
east




day_of_week Box Plot
east



Month-wise Box Plot
east




day_of Month Box Plot
east




برای جنوب


Year-wise Box Plot
south




day_of_week Box Plot
south



Month-wise Box Plot
south




day_of Month Box Plot
south




برای شمال


Year-wise Box Plot
north




day_of_week Box Plot
north

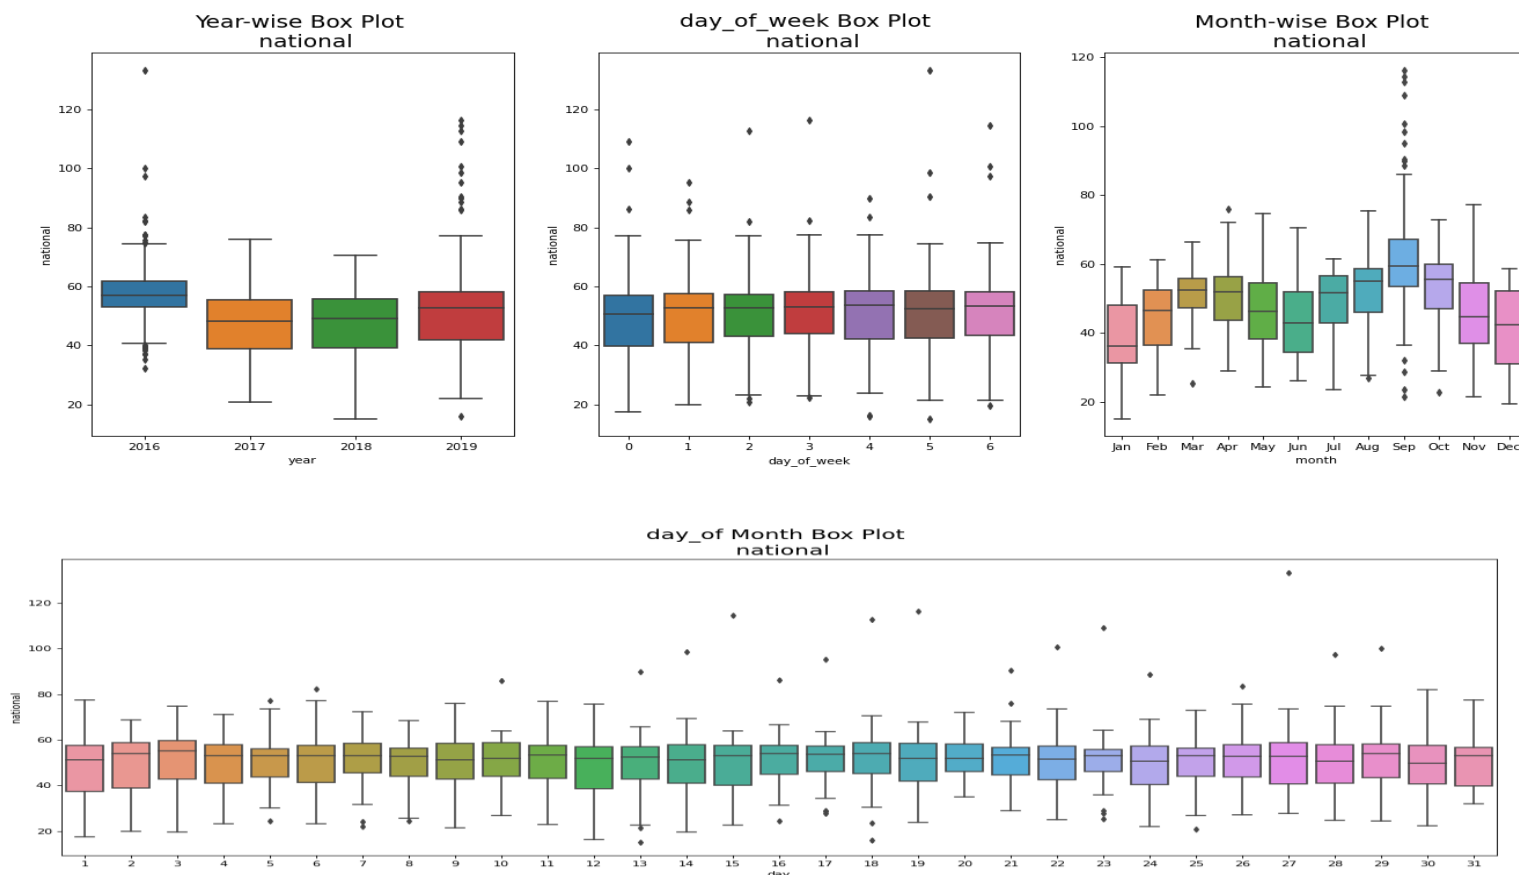


Month-wise Box Plot
north



day_of Month Box Plot
north





تحلیل باکس پلات های بالا :

- آلودگی در سال های مختلف متفاوت است و این تفاوت در منطق مختلف هم با هم متفاوت است، مثلا در جنوب آلودگی در سال ۲۰۱۷ نسبت به بقیه سال ها کمتر بوده و در سال های ۲۰۱۸ و ۲۰۱۹ از دو سال قبل بیشتر بوده است و در منطقه شرق تقریبا آلودگی در ۴ سال به یک صورت بوده است .
- در تمام مناطق آلودگی تقریبا در روز های هفته به یک صورت بوده است و روز هفته تفاوت به سزایی در میزان آلودگی ندارد.
- در تمام مناطق آلودگی بسته به ماه سال متفاوت بوده است مثلا در ماه های سپتامبر، مارچ، اپریل و اگست بیشترین آلودگی و در ماه های ژانویه و جون کمترین میزان آلودگی است .
- در تمام مناطق آلودگی بسته به روز ماه کمی متفاوت بوده است ولی این تفاوت از روی نمودار کامل مشخص نیست که در ادامه با نمودار های دیگر این تفاوت بهتر تحلیل می شود .
- Outlier های موجود مشخص می کند که در سپتامبر ۲۰۱۹ آلودگی هوا در تمامیه مناطق به صورت غیر عادی زیاد شده است. همچنین در مناطق مختلف موارد غیر عادی دیگر نیز موجود است که می توان هر یک از آن ها را تحلیل کرد

در بررسی سری های زمانی یکی از پارامتر های مهم stationarity سری های زمانی است ، باید بررسی کنیم داده ها stationarity است یا خیر و اگر stationarity نیست سعی کنیم داده ها را stationarity بکنیم.


بررسی stationarity بود از دو طریق می تواند انجام شود

میانگین داده ها تقریباً ثابت باشد

تست Dickey-Fuller Test : که در این تست فرض صفر این است که سری stationarity نیست اگر p-value کمتر از ۰,۰۵ باشد فرض صفر رد می شود و سری stationarity است .


خوشبختانه همانگونه که نتیج زیر نشان می دهد (هم ثابت بودن میانگین و هم تست ADH) برای تمام مناطق سری ما stationarity می باشد و نیاز به stationarity کردن آن نمی باشد .

برای منطقه غرب




```
Results of Dickey-Fuller Test of west:
Test Statistic      -4.163835
p-value             0.000758
#Lags Used          21.000000
Number of Observations Used  1347.000000
Critical Value (1%)  -3.435214
Critical Value (5%)  -2.863688
Critical Value (10%) -2.567914
dtype: float64
```

برای منطقه شرق



```
Results of Dickey-Fuller Test of east:
Test Statistic      -6.512272e+00
p-value             1.092917e-08
#Lags Used          8.000000e+00
Number of Observations Used  1.360000e+03
Critical Value (1%)  -3.435167e+00
Critical Value (5%)  -2.863668e+00
Critical Value (10%) -2.567903e+00
dtype: float64
```


برای منطقه جنوب



```
Results of Dickey-Fuller Test of south:
Test Statistic      -5.879593e+00
p-value             3.100892e-07
#Lags Used          8.000000e+00
Number of Observations Used  1.360000e+03
Critical Value (1%)  -3.435167e+00
Critical Value (5%)  -2.863668e+00
Critical Value (10%) -2.567903e+00
dtype: float64
```


برای منطقه ی شمال

Rolling Mean & Standard Deviation
north




Results of Dickey-Fuller Test of north:

Test Statistic	-6.551393e+00
p-value	8.832829e-09
#Lags Used	9.000000e+00
Number of Observations Used	1.359000e+03
Critical Value (1%)	-3.435171e+00
Critical Value (5%)	-2.863669e+00
Critical Value (10%)	-2.567904e+00

dtype: float64

برای منطقه مرکز

Rolling Mean & Standard Deviation
north



--


Results of Dickey-Fuller Test of central:

Test Statistic	-6.311821e+00
p-value	3.220693e-08
#Lags Used	8.000000e+00
Number of Observations Used	1.360000e+03
Critical Value (1%)	-3.435167e+00
Critical Value (5%)	-2.863668e+00
Critical Value (10%)	-2.567903e+00

dtype: float64

برای کل کشور

Rolling Mean & Standard Deviation
national



--

Results of Dickey-Fuller Test of national:

Test Statistic	-4.685718
p-value	0.000090
#Lags Used	16.000000
Number of Observations Used	1352.000000
Critical Value (1%)	-3.435196
Critical Value (5%)	-2.863680
Critical Value (10%)	-2.567909

dtype: float64

برای پیش بینی سری زمانی استفاده از دو روش مناسب است

۱. شبکه عصبی بازگشتی

۲. روش های آماری مانند SARIMAX (seasonal autoregressive integrated moving average)

در روش شبکه های عصبی بازگشتی برای پیش بینی سری زمانی ورودی های شبکه عصبی تنها زمان های گذشته ی خروجی می باشد. بدین ترتیب شبکه عصبی به اصطلاح حافظه دار می شود. برای پیاده سازی این روش در پایتون نیاز به کتاب خانه ی tensorflow می باشد که به دلیل یابین بودن ویژگی های سخت افزاری و نرم افزاری سیستم مورد نظر امکان استفاده از این کتابخانه در این روش نبوده است.

در روش ARIMA

این روش تکامل یافته ی روش ARMA می باشد. روش ARMA که برای سری های stationarity می باشد هر یک از داده های سری زمانی را به صورت ترکیب خطی از داده های قبلی (قسمت AR) و خطای داده های قبلی (قسمت MA) می داند در این روش باید دو پارامتر p, q مشخص گردد که این دو پارامتر مشخص می کند هر تا چه میزان داده های قبلی و خطای آن ها برای تخمین باید استفاده شود.

فرمول کلی این روش به صورت زیر می باشد :

$$X_t - \alpha_1 X_{t-1} - \dots - \alpha_{p'} X_{t-p'} = \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q},$$



روش ARIMAX برای داده های non-stationarity هم استفاده می شود و با استفاده از قسمت integrated مشکل non-stationarity بودن سری را حل می کند

در بعضی از سری های زمانی ما قسمت seasonal داریم یعنی یک الگو در یک ماه یا یه هفته و .. تکرار شده است در این حالت از روش SARMAX استفاده می شود.

در قسمت بعدی می خواهیم trend هر منطقه را ببینیم و ببینیم آیا seasonality دارد یا نه و اگر دارد مربوط به چه زمانی است

نتایج همه مناطق تقریباً مشابه هم شد ما برای اختصار فقط ناحیه ی غرب را می آوریم ولی در کد برای همه ی نواحی موجود است .

الگو، ۹، ۱۰، ۱۱، ۱۲، ۱۳، ۱۴، ۱۵، ۱۶، ۱۷، ۱۸، ۱۹، ۲۰، ۲۱، ۲۲، ۲۳، ۲۴، ۲۵، ۲۶، ۲۷، ۲۸، ۲۹، ۳۰، ۳۱، ۳۲، ۳۳، ۳۴، ۳۵، ۳۶، ۳۷، ۳۸، ۳۹، ۴۰، ۴۱، ۴۲، ۴۳، ۴۴، ۴۵، ۴۶، ۴۷، ۴۸، ۴۹، ۵۰، ۵۱، ۵۲، ۵۳، ۵۴، ۵۵، ۵۶، ۵۷، ۵۸، ۵۹، ۶۰، ۶۱، ۶۲، ۶۳، ۶۴، ۶۵، ۶۶، ۶۷، ۶۸، ۶۹، ۷۰، ۷۱، ۷۲، ۷۳، ۷۴، ۷۵، ۷۶، ۷۷، ۷۸، ۷۹، ۸۰، ۸۱، ۸۲، ۸۳، ۸۴، ۸۵، ۸۶، ۸۷، ۸۸، ۸۹، ۹۰، ۹۱، ۹۲، ۹۳، ۹۴، ۹۵، ۹۶، ۹۷، ۹۸، ۹۹، ۱۰۰، ۱۰۱، ۱۰۲، ۱۰۳، ۱۰۴، ۱۰۵، ۱۰۶، ۱۰۷، ۱۰۸، ۱۰۹، ۱۱۰، ۱۱۱، ۱۱۲، ۱۱۳، ۱۱۴، ۱۱۵، ۱۱۶، ۱۱۷، ۱۱۸، ۱۱۹، ۱۲۰، ۱۲۱، ۱۲۲، ۱۲۳، ۱۲۴، ۱۲۵، ۱۲۶، ۱۲۷، ۱۲۸، ۱۲۹، ۱۳۰، ۱۳۱، ۱۳۲، ۱۳۳، ۱۳۴، ۱۳۵، ۱۳۶، ۱۳۷، ۱۳۸، ۱۳۹، ۱۴۰، ۱۴۱، ۱۴۲، ۱۴۳، ۱۴۴، ۱۴۵، ۱۴۶، ۱۴۷، ۱۴۸، ۱۴۹، ۱۵۰، ۱۵۱، ۱۵۲، ۱۵۳، ۱۵۴، ۱۵۵، ۱۵۶، ۱۵۷، ۱۵۸، ۱۵۹، ۱۶۰، ۱۶۱، ۱۶۲، ۱۶۳، ۱۶۴، ۱۶۵، ۱۶۶، ۱۶۷، ۱۶۸، ۱۶۹، ۱۷۰، ۱۷۱، ۱۷۲، ۱۷۳، ۱۷۴، ۱۷۵، ۱۷۶، ۱۷۷، ۱۷۸، ۱۷۹، ۱۸۰، ۱۸۱، ۱۸۲، ۱۸۳، ۱۸۴، ۱۸۵، ۱۸۶، ۱۸۷، ۱۸۸، ۱۸۹، ۱۹۰، ۱۹۱، ۱۹۲، ۱۹۳، ۱۹۴، ۱۹۵، ۱۹۶، ۱۹۷، ۱۹۸، ۱۹۹، ۲۰۰، ۲۰۱، ۲۰۲، ۲۰۳، ۲۰۴، ۲۰۵، ۲۰۶، ۲۰۷، ۲۰۸، ۲۰۹، ۲۱۰، ۲۱۱، ۲۱۲، ۲۱۳، ۲۱۴، ۲۱۵، ۲۱۶، ۲۱۷، ۲۱۸، ۲۱۹، ۲۲۰، ۲۲۱، ۲۲۲، ۲۲۳، ۲۲۴، ۲۲۵، ۲۲۶، ۲۲۷، ۲۲۸، ۲۲۹، ۲۳۰، ۲۳۱، ۲۳۲، ۲۳۳، ۲۳۴، ۲۳۵، ۲۳۶، ۲۳۷، ۲۳۸، ۲۳۹، ۲۴۰، ۲۴۱، ۲۴۲، ۲۴۳، ۲۴۴، ۲۴۵، ۲۴۶، ۲۴۷، ۲۴۸، ۲۴۹، ۲۵۰، ۲۵۱، ۲۵۲، ۲۵۳، ۲۵۴، ۲۵۵، ۲۵۶، ۲۵۷، ۲۵۸، ۲۵۹، ۲۶۰، ۲۶۱، ۲۶۲، ۲۶۳، ۲۶۴، ۲۶۵، ۲۶۶، ۲۶۷، ۲۶۸، ۲۶۹، ۲۷۰، ۲۷۱، ۲۷۲، ۲۷۳، ۲۷۴، ۲۷۵، ۲۷۶، ۲۷۷، ۲۷۸، ۲۷۹، ۲۸۰، ۲۸۱، ۲۸۲، ۲۸۳، ۲۸۴، ۲۸۵، ۲۸۶، ۲۸۷، ۲۸۸، ۲۸۹، ۲۹۰، ۲۹۱، ۲۹۲، ۲۹۳، ۲۹۴، ۲۹۵، ۲۹۶، ۲۹۷، ۲۹۸، ۲۹۹، ۳۰۰، ۳۰۱، ۳۰۲، ۳۰۳، ۳۰۴، ۳۰۵، ۳۰۶، ۳۰۷، ۳۰۸، ۳۰۹، ۳۱۰، ۳۱۱، ۳۱۲، ۳۱۳، ۳۱۴، ۳۱۵، ۳۱۶، ۳۱۷، ۳۱۸، ۳۱۹، ۳۲۰، ۳۲۱، ۳۲۲، ۳۲۳، ۳۲۴، ۳۲۵، ۳۲۶، ۳۲۷، ۳۲۸، ۳۲۹، ۳۳۰، ۳۳۱، ۳۳۲، ۳۳۳، ۳۳۴، ۳۳۵، ۳۳۶، ۳۳۷، ۳۳۸، ۳۳۹، ۳۴۰، ۳۴۱، ۳۴۲، ۳۴۳، ۳۴۴، ۳۴۵، ۳۴۶، ۳۴۷، ۳۴۸، ۳۴۹، ۳۵۰، ۳۵۱، ۳۵۲، ۳۵۳، ۳۵۴، ۳۵۵، ۳۵۶، ۳۵۷، ۳۵۸، ۳۵۹، ۳۶۰، ۳۶۱، ۳۶۲، ۳۶۳، ۳۶۴، ۳۶۵، ۳۶۶، ۳۶۷، ۳۶۸، ۳۶۹، ۳۷۰، ۳۷۱، ۳۷۲، ۳۷۳، ۳۷۴، ۳۷۵، ۳۷۶، ۳۷۷، ۳۷۸، ۳۷۹، ۳۸۰، ۳۸۱، ۳۸۲، ۳۸۳، ۳۸۴، ۳۸۵، ۳۸۶، ۳۸۷، ۳۸۸، ۳۸۹، ۳۹۰، ۳۹۱، ۳۹۲، ۳۹۳، ۳۹۴، ۳۹۵، ۳۹۶، ۳۹۷، ۳۹۸، ۳۹۹، ۴۰۰، ۴۰۱، ۴۰۲، ۴۰۳، ۴۰۴، ۴۰۵، ۴۰۶، ۴۰۷، ۴۰۸، ۴۰۹، ۴۱۰، ۴۱۱، ۴۱۲، ۴۱۳، ۴۱۴، ۴۱۵، ۴۱۶، ۴۱۷، ۴۱۸، ۴۱۹، ۴۲۰، ۴۲۱، ۴۲۲، ۴۲۳، ۴۲۴، ۴۲۵، ۴۲۶، ۴۲۷، ۴۲۸، ۴۲۹، ۴۳۰، ۴۳۱، ۴۳۲، ۴۳۳، ۴۳۴، ۴۳۵، ۴۳۶، ۴۳۷، ۴۳۸، ۴۳۹، ۴۴۰، ۴۴۱، ۴۴۲، ۴۴۳، ۴۴۴، ۴۴۵، ۴۴۶، ۴۴۷، ۴۴۸، ۴۴۹، ۴۵۰، ۴۵۱، ۴۵۲، ۴۵۳، ۴۵۴، ۴۵۵، ۴۵۶، ۴۵۷، ۴۵۸، ۴۵۹، ۴۶۰، ۴۶۱، ۴۶۲، ۴۶۳، ۴۶۴، ۴۶۵، ۴۶۶، ۴۶۷، ۴۶۸، ۴۶۹، ۴۷۰، ۴۷۱، ۴۷۲، ۴۷۳، ۴۷۴، ۴۷۵، ۴۷۶، ۴۷۷، ۴۷۸، ۴۷۹، ۴۸۰، ۴۸۱، ۴۸۲، ۴۸۳، ۴۸۴، ۴۸۵، ۴۸۶، ۴۸۷، ۴۸۸، ۴۸۹، ۴۹۰، ۴۹۱، ۴۹۲، ۴۹۳، ۴۹۴، ۴۹۵، ۴۹۶، ۴۹۷، ۴۹۸، ۴۹۹، ۵۰۰، ۵۰۱، ۵۰۲، ۵۰۳، ۵۰۴، ۵۰۵، ۵۰۶، ۵۰۷، ۵۰۸، ۵۰۹، ۵۱۰، ۵۱۱، ۵۱۲، ۵۱۳، ۵۱۴، ۵۱۵، ۵۱۶، ۵۱۷، ۵۱۸، ۵۱۹، ۵۲۰، ۵۲۱، ۵۲۲، ۵۲۳، ۵۲۴، ۵۲۵، ۵۲۶، ۵۲۷، ۵۲۸، ۵۲۹، ۵۳۰، ۵۳۱، ۵۳۲، ۵۳۳، ۵۳۴، ۵۳۵، ۵۳۶، ۵۳۷، ۵۳۸، ۵۳۹، ۵۴۰، ۵۴۱، ۵۴۲، ۵۴۳، ۵۴۴، ۵۴۵، ۵۴۶، ۵۴۷، ۵۴۸، ۵۴۹، ۵۵۰، ۵۵۱، ۵۵۲، ۵۵۳، ۵۵۴، ۵۵۵، ۵۵۶، ۵۵۷، ۵۵۸، ۵۵۹، ۵۶۰، ۵۶۱، ۵۶۲، ۵۶۳، ۵۶۴، ۵۶۵، ۵۶۶، ۵۶۷، ۵۶۸، ۵۶۹، ۵۷۰، ۵۷۱، ۵۷۲، ۵۷۳، ۵۷۴، ۵۷۵، ۵۷۶، ۵۷۷، ۵۷۸، ۵۷۹، ۵۸۰، ۵۸۱، ۵۸۲، ۵۸۳، ۵۸۴، ۵۸۵، ۵۸۶، ۵۸۷، ۵۸۸، ۵۸۹، ۵۹۰، ۵۹۱، ۵۹۲، ۵۹۳، ۵۹۴، ۵۹۵، ۵۹۶، ۵۹۷، ۵۹۸، ۵۹۹، ۶۰۰، ۶۰۱، ۶۰۲، ۶۰۳، ۶۰۴، ۶۰۵، ۶۰۶، ۶۰۷، ۶۰۸، ۶۰۹، ۶۱۰، ۶۱۱، ۶۱۲، ۶۱۳، ۶۱۴، ۶۱۵، ۶۱۶، ۶۱۷، ۶۱۸، ۶۱۹، ۶۲۰، ۶۲۱، ۶۲۲، ۶۲۳، ۶۲۴، ۶۲۵، ۶۲۶، ۶۲۷، ۶۲۸، ۶۲۹، ۶۳۰، ۶۳۱، ۶۳۲، ۶۳۳، ۶۳۴، ۶۳۵، ۶۳۶، ۶۳۷، ۶۳۸، ۶۳۹، ۶۴۰، ۶۴۱، ۶۴۲، ۶۴۳، ۶۴۴، ۶۴۵، ۶۴۶، ۶۴۷، ۶۴۸، ۶۴۹، ۶۵۰، ۶۵۱، ۶۵۲، ۶۵۳، ۶۵۴، ۶۵۵، ۶۵۶، ۶۵۷، ۶۵۸، ۶۵۹، ۶۶۰، ۶۶۱، ۶۶۲، ۶۶۳، ۶۶۴، ۶۶۵، ۶۶۶، ۶۶۷، ۶۶۸، ۶۶۹، ۶۷۰، ۶۷۱، ۶۷۲، ۶۷۳، ۶۷۴، ۶۷۵، ۶۷۶، ۶۷۷، ۶۷۸، ۶۷۹، ۶۸۰، ۶۸۱، ۶۸۲، ۶۸۳، ۶۸۴، ۶۸۵، ۶۸۶، ۶۸۷، ۶۸۸، ۶۸۹، ۶۹۰، ۶۹۱، ۶۹۲، ۶۹۳، ۶۹۴، ۶۹۵، ۶۹۶، ۶۹۷، ۶۹۸، ۶۹۹، ۷۰۰، ۷۰۱، ۷۰۲، ۷۰۳، ۷۰۴، ۷۰۵، ۷۰۶، ۷۰۷، ۷۰۸، ۷۰۹، ۷۱۰، ۷۱۱، ۷۱۲، ۷۱۳، ۷۱۴، ۷۱۵، ۷۱۶، ۷۱۷، ۷۱۸، ۷۱۹، ۷۲۰، ۷۲۱، ۷۲۲، ۷۲۳، ۷۲۴، ۷۲۵، ۷۲۶، ۷۲۷، ۷۲۸، ۷۲۹، ۷۳۰، ۷۳۱، ۷۳۲، ۷۳۳، ۷۳۴، ۷۳۵، ۷۳۶، ۷۳۷، ۷۳۸، ۷۳۹، ۷۴۰، ۷۴۱، ۷۴۲، ۷۴۳، ۷۴۴، ۷۴۵، ۷۴۶، ۷۴۷، ۷۴۸، ۷۴۹، ۷۵۰، ۷۵۱، ۷۵۲، ۷۵۳، ۷۵۴، ۷۵۵، ۷۵۶، ۷۵۷، ۷۵۸، ۷۵۹، ۷۶۰، ۷۶۱، ۷۶۲، ۷۶۳، ۷۶۴، ۷۶۵، ۷۶۶، ۷۶۷، ۷۶۸، ۷۶۹، ۷۷۰، ۷۷۱، ۷۷۲، ۷۷۳، ۷۷۴، ۷۷۵، ۷۷۶، ۷۷۷، ۷۷۸، ۷۷۹، ۷۸۰، ۷۸۱، ۷۸۲، ۷۸۳، ۷۸۴، ۷۸۵، ۷۸۶، ۷۸۷، ۷۸۸، ۷۸۹، ۷۹۰، ۷۹۱، ۷۹۲، ۷۹۳، ۷۹۴، ۷۹۵، ۷۹۶، ۷۹۷، ۷۹۸، ۷۹۹، ۸۰۰، ۸۰۱، ۸۰۲، ۸۰۳، ۸۰۴، ۸۰۵، ۸۰۶، ۸۰۷، ۸۰۸، ۸۰۹، ۸۱۰، ۸۱۱، ۸۱۲، ۸۱۳، ۸۱۴، ۸۱۵، ۸۱۶، ۸۱۷، ۸۱۸، ۸۱۹، ۸۲۰، ۸۲۱، ۸۲۲، ۸۲۳، ۸۲۴، ۸۲۵، ۸۲۶، ۸۲۷، ۸۲۸، ۸۲۹، ۸۳۰، ۸۳۱، ۸۳۲، ۸۳۳، ۸۳۴، ۸۳۵، ۸۳۶، ۸۳۷، ۸۳۸، ۸۳۹، ۸۴۰، ۸۴۱، ۸۴۲، ۸۴۳، ۸۴۴، ۸۴۵، ۸۴۶، ۸۴۷، ۸۴۸، ۸۴۹، ۸۵۰، ۸۵۱، ۸۵۲، ۸۵۳، ۸۵۴، ۸۵۵، ۸۵۶، ۸۵۷، ۸۵۸، ۸۵۹، ۸۶۰، ۸۶۱، ۸۶۲، ۸۶۳، ۸۶۴، ۸۶۵، ۸۶۶، ۸۶۷، ۸۶۸، ۸۶۹، ۸۷۰، ۸۷۱، ۸۷۲، ۸۷۳، ۸۷۴، ۸۷۵، ۸۷۶، ۸۷۷، ۸۷۸، ۸۷۹، ۸۸۰، ۸۸۱، ۸۸۲، ۸۸۳، ۸۸۴، ۸۸۵، ۸۸۶، ۸۸۷، ۸۸۸، ۸۸۹، ۸۹۰، ۸۹۱، ۸۹۲، ۸۹۳، ۸۹۴، ۸۹۵، ۸۹۶، ۸۹۷، ۸۹۸، ۸۹۹، ۹۰۰، ۹۰۱، ۹۰۲، ۹۰۳، ۹۰۴، ۹۰۵، ۹۰۶، ۹۰۷، ۹۰۸، ۹۰۹، ۹۱۰، ۹۱۱، ۹۱۲، ۹۱۳، ۹۱۴، ۹۱۵، ۹۱۶، ۹۱۷، ۹۱۸، ۹۱۹، ۹۲۰، ۹۲۱، ۹۲۲، ۹۲۳، ۹۲۴، ۹۲۵، ۹۲۶، ۹۲۷، ۹۲۸، ۹۲۹، ۹۳۰، ۹۳۱، ۹۳۲، ۹۳۳، ۹۳۴، ۹۳۵، ۹۳۶، ۹۳۷، ۹۳۸، ۹۳۹، ۹۴۰، ۹۴۱، ۹۴۲، ۹۴۳، ۹۴۴، ۹۴۵، ۹۴۶، ۹۴۷، ۹۴۸، ۹۴۹، ۹۵۰، ۹۵۱، ۹۵۲، ۹۵۳، ۹۵۴، ۹۵۵، ۹۵۶، ۹۵۷، ۹۵۸، ۹۵۹، ۹۶۰، ۹۶۱، ۹۶۲، ۹۶۳، ۹۶۴، ۹۶۵، ۹۶۶، ۹۶۷، ۹۶۸، ۹۶۹، ۹۷۰، ۹۷۱، ۹۷۲، ۹۷۳، ۹۷۴، ۹۷۵، ۹۷۶، ۹۷۷، ۹۷۸، ۹۷۹، ۹۸۰، ۹۸۱، ۹۸۲، ۹۸۳، ۹۸۴، ۹۸۵، ۹۸۶، ۹۸۷، ۹۸۸، ۹۸۹، ۹۹۰، ۹۹۱، ۹۹۲، ۹۹۳، ۹۹۴، ۹۹۵، ۹۹۶، ۹۹۷، ۹۹۸، ۹۹۹، ۱۰۰۰، ۱۰۰۱، ۱۰۰۲، ۱۰۰۳، ۱۰۰۴، ۱۰۰۵، ۱۰۰۶، ۱۰۰۷، ۱۰۰۸، ۱۰۰۹، ۱۰۰۱۰، ۱۰۰۱۱، ۱۰۰۱۲، ۱۰۰۱۳، ۱۰۰۱۴، ۱۰۰۱۵، ۱۰۰۱۶، ۱۰۰۱۷، ۱۰۰۱۸، ۱۰۰۱۹، ۱۰۰۲۰، ۱۰۰۲۱، ۱۰۰۲۲، ۱۰۰۲۳، ۱۰۰۲۴، ۱۰۰۲۵، ۱۰۰۲۶، ۱۰۰۲۷، ۱۰۰۲۸، ۱۰۰۲۹، ۱۰۰۳۰، ۱۰۰۳۱، ۱۰۰۳۲، ۱۰۰۳۳، ۱۰۰۳۴، ۱۰۰۳۵، ۱۰۰۳۶، ۱۰۰۳۷، ۱۰۰۳۸، ۱۰۰۳۹، ۱۰۰۴۰، ۱۰۰۴۱، ۱۰۰۴۲، ۱۰۰۴۳، ۱۰۰۴۴، ۱۰۰۴۵، ۱۰۰۴۶، ۱۰۰۴۷، ۱۰۰۴۸، ۱۰۰۴۹، ۱۰۰۵۰، ۱۰۰۵۱، ۱۰۰۵۲، ۱۰۰۵۳، ۱۰۰۵۴، ۱۰۰۵۵، ۱۰۰۵۶، ۱۰۰۵۷، ۱۰۰۵۸، ۱۰۰۵۹، ۱۰۰۶۰، ۱۰۰۶۱، ۱۰۰۶۲، ۱۰۰۶۳، ۱۰۰۶۴، ۱۰۰۶۵، ۱۰۰۶۶، ۱۰۰۶۷، ۱۰۰۶۸، ۱۰۰۶۹، ۱۰۰۷۰، ۱۰۰۷۱، ۱۰۰۷۲، ۱۰۰۷۳، ۱۰۰۷۴، ۱۰۰۷۵، ۱۰۰۷۶، ۱۰۰۷۷، ۱۰۰۷۸، ۱۰۰۷۹، ۱۰۰۸۰، ۱۰۰۸۱، ۱۰۰۸۲، ۱۰۰۸۳، ۱۰۰۸۴، ۱۰۰۸۵، ۱۰۰۸۶، ۱۰۰۸۷، ۱۰۰۸۸، ۱۰۰۸۹، ۱۰۰۹۰، ۱۰۰۹۱، ۱۰۰۹۲، ۱۰۰۹۳، ۱۰۰۹۴، ۱۰۰۹۵، ۱۰۰۹۶، ۱۰۰۹۷، ۱۰۰۹۸، ۱۰۰۹۹، ۱۰۱۰۰، ۱۰۱۰۱، ۱۰۱۰۲، ۱۰۱۰۳، ۱۰۱۰۴، ۱۰۱۰۵، ۱۰۱۰۶، ۱۰۱۰۷، ۱۰۱۰۸، ۱۰۱۰۹، ۱۰۱۱۰، ۱۰۱۱۱، ۱۰۱۱۲، ۱۰۱۱۳، ۱۰۱۱۴، ۱۰۱۱۵، ۱۰۱۱۶، ۱۰۱۱۷، ۱۰۱۱۸، ۱۰۱۱۹، ۱۰۱۲۰، ۱۰۱۲۱، ۱۰۱۲۲، ۱۰۱۲۳، ۱۰۱۲۴، ۱۰۱۲۵، ۱۰۱۲۶، ۱۰۱۲۷، ۱۰۱۲۸، ۱۰۱۲۹، ۱۰۱۳۰، ۱۰۱۳۱، ۱۰۱۳۲، ۱۰۱۳۳، ۱۰۱۳۴، ۱۰۱۳۵، ۱۰۱۳۶، ۱۰۱۳۷، ۱۰۱۳۸، ۱۰۱۳۹، ۱۰۱۴۰، ۱۰۱۴۱، ۱۰۱۴۲، ۱۰۱۴۳، ۱۰۱۴۴، ۱۰۱۴۵، ۱۰۱۴۶، ۱۰۱۴۷، ۱۰۱۴۸، ۱۰۱۴۹، ۱۰۱۵۰، ۱۰۱۵۱، ۱۰۱۵۲، ۱۰۱۵۳، ۱۰۱۵۴، ۱۰۱۵۵، ۱۰۱۵۶، ۱۰۱۵۷، ۱۰۱۵۸، ۱۰۱۵۹، ۱۰۱۶۰، ۱۰۱۶۱، ۱۰۱۶۲، ۱۰۱۶۳، ۱۰۱۶۴، ۱۰۱۶۵، ۱۰۱۶۶، ۱۰۱۶۷، ۱۰۱۶۸، ۱۰۱۶۹، ۱۰۱۷۰، ۱۰۱۷۱، ۱۰۱۷۲، ۱۰۱۷۳، ۱۰۱۷۴، ۱۰۱۷۵، ۱۰۱۷۶، ۱۰۱۷۷، ۱۰۱۷۸، ۱۰۱۷۹، ۱۰۱۸۰، ۱۰۱۸۱، ۱۰۱۸۲، ۱۰۱۸۳، ۱۰۱۸۴، ۱۰۱۸۵، ۱۰۱۸۶، ۱۰۱۸۷، ۱۰۱۸۸، ۱۰۱۸۹، ۱۰۱۹۰، ۱۰۱۹۱، ۱۰۱۹۲، ۱۰۱۹۳، ۱۰۱۹۴، ۱۰۱۹۵، ۱۰۱۹۶، ۱۰۱۹۷، ۱۰۱۹۸، ۱۰۱۹۹، ۱۰۲۰۰، ۱۰۲۰۱، ۱۰۲۰۲، ۱۰۲۰۳، ۱۰۲۰۴، ۱۰۲۰۵، ۱۰۲۰۶، ۱۰۲۰۷، ۱۰۲۰۸، ۱۰۲۰۹، ۱۰۲۱۰، ۱۰۲۱۱، ۱۰۲۱۲، ۱۰۲۱۳، ۱۰۲۱۴، ۱۰۲۱۵، ۱۰۲۱۶، ۱۰۲۱۷، ۱۰۲۱۸، ۱۰۲۱۹، ۱۰۲۲۰، ۱۰۲۲۱، ۱۰۲۲۲، ۱۰۲۲۳، ۱۰۲۲۴، ۱۰۲۲۵، ۱۰۲۲۶، ۱۰۲۲۷، ۱۰۲۲۸، ۱۰۲۲۹، ۱۰۲۳۰، ۱۰۲۳۱، ۱۰۲۳۲، ۱۰۲۳۳، ۱۰۲۳۴، ۱۰۲۳۵، ۱۰۲۳۶، ۱۰۲۳۷، ۱۰۲۳۸، ۱۰۲۳۹، ۱۰۲۴۰، ۱۰۲۴۱، ۱۰۲۴۲، ۱۰۲۴۳، ۱۰۲۴۴، ۱۰۲۴۵، ۱۰۲۴۶، ۱۰۲۴۷، ۱۰۲۴۸، ۱۰۲۴۹، ۱۰۲۵۰، ۱۰۲۵۱، ۱۰۲۵۲، ۱۰۲۵۳، ۱۰۲۵۴، ۱۰۲۵۵، ۱۰۲۵۶، ۱۰۲۵۷، ۱۰۲۵۸، ۱۰۲۵۹، ۱۰۲۶۰، ۱۰۲۶۱، ۱۰۲۶۲، ۱۰۲۶۳، ۱۰۲۶۴، ۱۰۲۶۵، ۱۰۲۶۶، ۱۰۲۶۷، ۱۰۲۶۸، ۱۰۲۶۹، ۱۰۲۷۰، ۱۰۲۷۱، ۱۰۲۷۲، ۱۰۲۷۳، ۱۰۲۷۴، ۱۰۲۷۵، ۱۰۲۷۶، ۱۰۲۷۷، ۱۰۲۷۸، ۱۰۲۷۹، ۱۰۲۸۰، ۱۰۲۸۱، ۱۰۲۸۲، ۱۰۲۸۳، ۱۰۲۸۴، ۱۰۲۸۵، ۱۰۲۸۶، ۱۰۲۸۷، ۱۰۲۸۸، ۱۰۲۸۹، ۱۰۲۹۰، ۱۰۲۹۱، ۱۰۲۹۲، ۱۰۲۹۳، ۱۰۲۹۴، ۱۰۲۹۵، ۱۰۲۹۶، ۱۰۲۹۷، ۱۰۲۹۸، ۱۰۲۹۹، ۱۰۳۰۰، ۱۰۳۰۱، ۱۰۳۰۲، ۱۰۳۰۳، ۱۰۳۰۴، ۱۰۳۰۵، ۱۰۳۰۶، ۱۰۳۰۷، ۱۰۳۰۸، ۱۰۳۰۹، ۱۰۳۱۰، ۱۰۳۱۱، ۱۰۳۱۲، ۱۰۳۱۳، ۱۰




همانگونه که شکل های بالا نشان می دهد و همچنین در قسمت مربوط به باکس پلات ها هم دیدیم ماه های سال الگویی به نسبت قابل توجه دارند ، در شکل بالا می بینید که دامنه ی این الگو حدود ۵۰ است. که این مقدار قابل ملاحظه است. بعد از آن دامنه الگوی تغییرات روز های ماه به نسبت قابل ملاحظه است و بعد از آن روز های هفته ، که این دقیقا همان نتیجه ای است که باکس پلات ها هم به ما می دادند.

برای قسمت ARima نیاز به پیدا کردن سه ضریب d, p, q هستیم چون تمام سری های ما stationary است برای تمام مناطق $d=0$ می گیریم.


ضریب P برابر تعداد خطوطی قابل ملاحظه در partially correlation از دیفرانسیل داده ها q برابر تعداد خطوط با مقدار قابل ملاحظه در corolation دیفرانسل داده ها می باشد .

برای منطقه غرب داریم




در نتیجه $p=4$ و $q=2$

برای منطقه شرق داریم




در نتیجه $q=3$ و $p=4$

برای منطقه جنوب داریم




در نتیجه $q=3$ و $p=3$

برای منطقه شمال داریم




در نتیجه $q=2$ و $p=4$

برای منطقه مرکز داریم



در نتیجه $p=4$ و $q=2$

برای کل کشور داریم




در نتیجه $p=4$ و $q=3$

در ادامه به نتایج پیش بینی میپردازیم. قبل از تحلیل به نکات زیر توجه کنید:

- پیش بینی در دو حالت با در نظر گرفتن seasonality و بدون در نظر گرفتن آن انجام شده است. متأسفانه در حالت seasonality نتوانستیم از الگوی ماه های سال استفاده کنیم چون انجام پروسه اش برای سیستم میسر نبود برای همین از الگوی روز های ماه استفاده کردیم ولی متوجه شدیم نتایج خوب نیست برای همین مجبور شدیم داده ها را مثل مرحله قبل که ساعت به ساعت را به روزانه دریافت کردیم. حال باید سال به سال را به ماهانه تبدیل کنیم.
- برای تست نتایج اولاً هیستوگرام مقدار residual را کشیدیم و دیدیم تابعی گوسی است که این نشانه ی خوبی است در ثانی از معیار های همچون mean square error و rmse و استفاده کردیم تا بتوانیم معیار خوبی برای تحلیل نتایج داشته باشیم.
- نمودار پیش بینی در دو حالت رسم شده است در حالت forecast داده ها تا یک جایی در دسترس بوده اند و از یک نقطه به بعد داده ای نداشته ایم اما در حالت one step forecast فرض بر این است که در هر لحظه سری زمانی تا قبل از این لحظه در دسترس بوده است.
- سه مدل نتیجه در زیر بررسی شده است : در روش اول مدل ARIMA برای داده های روزانه در مدل دوم SARIMA با تناوب روزهای یک ماه برای داده های ماهانه و در مدل سوم SARIMA با تناوب ماه های سال برای داده های ماهانه

ابتدا لازم است برای داده ها وقتی به داده های ماهانه تبدیل می شود stationary بودن داده ها بررسی شود در این حالت جواب تست به صورت زیر است :

به علت یکسان بودن نتایج فقط قسمت بررسی کل کشور را در گزارش می آوریم، بقیه بررسی ها در کد موجود است




Results of Dickey-Fuller Test of national:

Test Statistic	-2.080365
p-value	0.252483
#Lags Used	10.000000
Number of Observations Used	35.000000
Critical Value (1%)	-3.632743
Critical Value (5%)	-2.948510
Critical Value (10%)	-2.613017
dtype:	float64

همانگونه که p-value نشان می دهد سری non-stationary است

حال بررسی می کنیم آیا دیفرانسیل تابع stationary است ؟















Results of Dickey-Fuller Test of national:

Test Statistic	-6.492602e+00
p-value	1.216141e-08
#Lags Used	2.000000e+00
Number of Observations Used	4.200000e+01
Critical Value (1%)	-3.596636e+00
Critical Value (5%)	-2.933297e+00
Critical Value (10%)	-2.604991e+00
dtype:	float64

همانگونه که ملاحظه می شود دیفرانسیل تابع stationary است پس باید d را در قسمت arima این دفعه ۱ بگذاریم. ضرایب p و q را هم با همان روشی که از قبل گفته شد. در آورده ایم که برای خلاصه کردن گزارش ماتریس correlation و partial correlation آورده نشده است.




نتیجه برای منطقه ی غرب













	prediction					one-step prediction				
	mape	me	mae	mpe	rmse	mape	me	mae	mpe	rmse
ARIMA_daily	0.17	-4.9	10.22	-0.031	15.01	0.09	-0.05	5.4	0.008	7.78
SARIMA_daily	0.21	-4.2	12.22	-0.019	17	0.14	-0.44	8.13	0.0133	10.96
ARIMA_monthly	0.13	3.37	7.1	0.08	8.6	0.08	-0.8	4.5	-0.005	5.84
SARIMA_monthly	0.2	8.5	10.04	0.177	11.61	0.07	-0.9	4.5	-0.007	6.7

برای منطقه ی شرق
















	prediction					one-step prediction				
	mape	me	mae	mpe	rmse	mape	me	mae	mpe	rmse
ARIMA_daily	0.21	-6.6	12.34	-0.05	16.75	0.1	-0.7	5.5	79	7.83
SARIMA_daily	0.24	-3.1	12.27	0.01	17.72	0.16	-0.4	8.5	0.015	11.39
ARIMA_monthly	0.13	3.92	7.21	0.089	8.1	0.07	-0.6	4.3	-0.002	6.02
SARIMA_monthly	0.1	-0.5	6.5	0.006	8.25	0.1	-0.4	5.7	0.0067	7.41

برای جنوب



















	prediction					one-step prediction				
	mape	me	mae	mpe	rmse	mape	me	mae	mpe	rmse
ARIMA_daily	0.18	-8	12.023	-0.078	18.2	0.086	-0.46	5.46	0.0067	8.4
SARIMA_daily	0.13	-0.43	8.38	0.011	12.01	0.19	-5.7	12.64	-0.04	18.74
ARIMA_monthly	0.098	1.397	5.91	0.04	8.2	0.067	-0.6	4.29	-0.002	6.5
SARIMA_monthly	0.18	9.01	10.1	0.16	11.75	0.07	0.48	4.88	0.018	7.5





برای شمال









	prediction					one-step prediction				
	mape	me	mae	mpe	rmse	mape	me	mae	mpe	rmse
ARIMA_daily	0.24	-6.629	13.5	-0.03	18.35	0.1	-0.53	5.65	0.01	8.46
SARIMA_daily	0.24	-4.74	13.59	-0.005	18.5	0.15	-0.48	8.42	0.016	11.677
ARIMA_monthly	0.1	-2.7	6.06	-0.028	9.1	0.1	-1.3	5.8	-0.012	6.9
SARIMA_monthly	0.09	-6.5	7.4	-0.1	10.8	0.093	-2.5	5.4	-0.03	7.2

برای کل کشور





	prediction					one-step prediction				
	mape	me	mae	mpe	rmse	mape	me	mae	mpe	rmse
ARIMA_daily	0.25	-10	15.4	-0.12	20.15	0.1	-0.5	6.01	0.01	8.46
SARIMA_daily	0.29	-9.7	16.8	-0.09	22.25	0.17	-0.5	9.3	0.017	12.5
ARIMA_monthly	0.2	5.58	9.4	0.15	11.2	0.1	-0.5	5.7	0.005	7.3
SARIMA_monthly	0.15	0.45	7.6	0.04	9.89	0.145	-1.2	7.35	-0.006	8.5

بررسی نتایج :

- همانگونه که از تمامی نمودار ها مشخص است نتایج داده های ماهیانه بهتر از داده های روزانه شده است در نمودار **residual** مشاهده می شود که در حالت ماهانه **residual** برای مقدار های بیشتر از ۲۰ را به خود اختصاص نداده است ولی برای سری روزانه **residual** بیشتر از ۴۰ نشده است .
- مقادیری که برای بررسی کیفیت کار تعریف شده است به صورت زیر می باشد

```
mape = np.mean(np.abs(forecast - actual)/np.abs(actual)) # MAPE
me = np.mean(forecast - actual) # ME
mae = np.mean(np.abs(forecast - actual)) # MAE
mpe = np.mean((forecast - actual)/actual) # MPE
rmse = np.mean((forecast - actual)**۲)**.۵ # RMSE
```

- همانگونه که از جداول مشخص است ، نتایج سری ماهانه بسیار بهتر از نتایج داده های روزانه است . و تمامی پارامتر های آن دارای اعداد مناسب تری است.
- از نمودارهایی مشخص است که همانگونه که انتظار می رفت این که روز های ماه را به صورت متناوب در نظر بگیریم پیش بینی خوب نمی شود و پیش بینی ها درست نمی شود. ولی همان گونه که باکس پلات هم می گفت متناوب گرفتن ماه های سال نتیجه ی خوبی می دهد .
- نتایج نشان می دهد که نتیجه ی پیش بینی **one step prediction** بهتر از پیشبینی است که داده های واقعی را از یک جا به بعد نداشته باشیم که این نتیجه قابل انتظار بوده است چرا که در **one step prediction** از داده های واقعی می خواهیم داده ی بعدی را پیش بینی کنیم ولی در پیش بینی واقعی از داده های پیش بینی می خواهیم یک داده ی جدید را پیش بینی کنیم که مطمئنا این روش دارای خطای بیشتری می باشد.